



(12) 发明专利

(10) 授权公告号 CN 119697701 B

(45) 授权公告日 2025.05.16

(21) 申请号 202510204142.8

H04W 24/02 (2009.01)

(22) 申请日 2025.02.24

(56) 对比文件

(65) 同一申请的已公布的文献号

CN 118484315 A, 2024.08.13

申请公布号 CN 119697701 A

审查员 孔月瑶

(43) 申请公布日 2025.03.25

(73) 专利权人 集美大学

地址 361000 福建省厦门市集美银江路185号

(72) 发明人 孙养龙 罗文乾 许伟坚 高志斌
许志平 周晓凤 魏林海

(74) 专利代理机构 厦门原创专利事务所(普通合伙) 35101

专利代理师 李明传

(51) Int.Cl.

H04W 28/08 (2023.01)

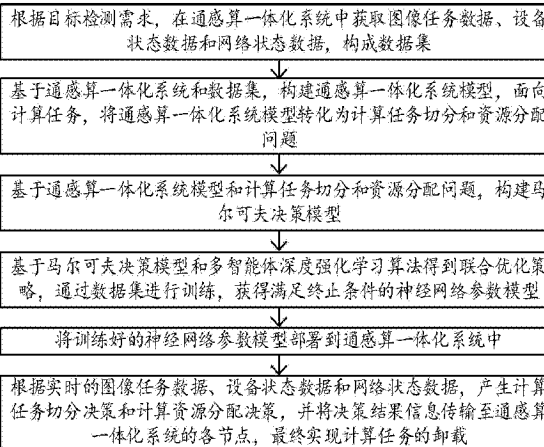
权利要求书8页 说明书20页 附图2页

(54) 发明名称

面向CNN网络的移动边缘计算动态卸载方法及设备介质

(57) 摘要

本发明公开了一种面向CNN网络的移动边缘计算动态卸载方法及设备介质,包括:在通感算一体化系统中获取图像任务数据、设备状态数据和网络状态数据,构成数据集;构建通感算一体化系统模型,面向计算任务,将通感算一体化系统模型转化为计算任务切分和资源分配问题;构建马尔可夫决策模型;采用基于多智能体深度强化学习算法的联合优化策略,通过训练图像任务数据和网络状态数据,获得满足终止条件的神经网络参数模型;将训练好的神经网络参数模型部署到系统中;根据实时的数据产生计算任务切分决策和计算资源分配决策,将决策结果信息传输至各节点,实现计算任务的卸载。本发明在网络环境和网络资源紧缺的条件下,实现计算任务的顺利执行。



1. 一种面向CNN网络的移动边缘计算动态卸载方法,其特征在于,包括如下步骤:

步骤1、根据目标检测需求,在通感算一体化系统中获取图像任务数据、设备状态数据和网络状态数据,构成数据集;

步骤2、基于通感算一体化系统和数据集,构建通感算一体化系统模型,面向计算任务,将通感算一体化系统模型转化为计算任务切分和资源分配问题;

步骤3、基于通感算一体化系统模型和计算任务切分和资源分配问题,构建马尔可夫决策模型;

步骤4、基于马尔可夫决策模型和多智能体深度强化学习算法得到联合优化策略,通过数据集进行训练,获得满足终止条件的神经网络参数模型;

步骤5、将训练好的神经网络参数模型部署到通感算一体化系统中;具体包括:

步骤51、根据环境动态信息,以设定的时间间隔,将训练好的神经网络参数同步至CNN网络中每个节点;所述时间间隔取决于新的神经网络参数训练过程是否收敛到新的状态;

步骤52、CNN网络中各节点基于获得的神经网络参数更新卸载策略和资源分配策略;

步骤53、CNN网络中各节点向通感算一体化系统反馈更新后的策略状态;

步骤6、根据实时的图像任务数据、设备状态数据和网络状态数据,产生计算任务切分决策和计算资源分配决策,并将决策结果信息传输至通感算一体化系统的各节点,最终实现计算任务的卸载。

2. 如权利要求1所述的面向CNN网络的移动边缘计算动态卸载方法,其特征在于,所述步骤1具体包括:

步骤11、根据用户提交的任务需求,所述通感算一体化系统由多个移动设备和感知设备构成;通感算一体化系统中的感知设备执行数据感知操作,采集并存储图像任务数据;通感算一体化系统同时记录移动设备的设备状态数据和网络状态数据;

步骤12、基于时隙对获取到的图像任务数据、设备状态数据和网络状态数据进行划分,形成设定时间段内的时序数据集;所述时隙是指具有设定时间长度的时间段,在该时间段内获取的数据均标记为该时隙的数据,所述时序数据是指具有时隙属性且按照时隙顺序编号的数据;

步骤13、将所述时序数据集划分为训练集、验证集和检测集。

3. 如权利要求2所述的面向CNN网络的移动边缘计算动态卸载方法,其特征在于,所述步骤2具体包括:

步骤21、通感算一体化系统中具有感知、计算、通信和存储功能的节点通过无线和有线通信的方式或者仅无线的方式相互连接,组成通感算一体化系统模型;所述通感算一体化系统模型按照步骤12中所划分的时隙工作;

步骤22、在基于时隙划分的通感算一体化系统模型中,用户在某一时隙发起任务请求;具体为:

在基于时隙划分的通感算一体化系统模型中,移动设备MMDs的集合 $\mathbf{M} = \{1, \dots, m, \dots, |\mathbf{M}|\}$,其中,设备m表示在多个移动设备MMDs中选择某一个移动设备MMD,实施任务感知,且均装载了基于CNN网络的计算模块,所述CNN网络包含多个CNN模型,不同的CNN模型对应不同的计算任务;边缘服务器MESs的集合 $\mathbf{S} = \{1, \dots, s, \dots, |\mathbf{S}|\}$,其中,设备s表示

在多个边缘服务器MESs中选择某一个边缘服务器MES,为周围的移动设备MMDs提供计算资源;设备间通过有线及无线或仅无线的方式组成通感算一体的网络,用户终端通过有线或无线的方式接入该通感算一体的网络,并在某一时隙向该通感算一体的网络发起任务请求;所述请求包含要感知的数据类型和所要求的数据处理要求;

步骤23、通感算一体化系统模型接收到该任务请求后,实施感知和计算过程;所述计算过程由数据传输和数据处理组成,所述感知和计算过程为通感算一体化过程;具体为:

移动设备MMDs负责计算卸载决策的实施,首先,移动设备MMDs选择其中一个设备 $s \in S$ 建立通信,将部分工作负载卸载到MES上;整个通感算一体化系统模型以时隙的方式运行,将 T 作为通感算一体化系统整个运行时间,把整个运行时间划分为 T 个长度相等的时隙,则时隙持续时间表示为 $\tau = \lfloor (T/T) \rfloor$, $\lfloor \cdot \rfloor$ 表示向下取整,MMDs在时隙 $t \in \{1, 2, \dots, T\}$ 开始时执行一个目标检测任务;具体的步骤如下:在每个时隙 t 开始时,设备 $m \in M$ 根据用户的提交的需求而生成不同的目标检测任务,不同类别任务所需的CNN模型是异构的,设备 $m \in M$ 需要选择合适的设备 $s \in S$ 建立联系并确定任务卸载部分,每个 $s \in S$ 收到多个 $m \in M$ 的请求并为其分配计算资源。

4.如权利要求3所述的面向CNN网络的移动边缘计算动态卸载方法,其特征在于,所述步骤23具体包括:

步骤231、根据CNN网络对任务进行分区卸载:

假定通感算一体化系统一共有 J 种CNN模型,对于第 j 个CNN模型,其中, $1 \leq j \leq J$,用 L_j 表示第 j 个CNN模型的总层数,第 j 个CNN模型每一层 l_j 的属性为 $(H_{l_j}, W_{l_j}, C_{l_j}^{in}, C_{l_j}^{out}, k_{l_j}, s_{l_j})$,其中, $1 \leq l_j \leq L_j$, $(H_{l_j}, W_{l_j}, C_{l_j}^{in})$ 分别表示 l_j 输入的高度、宽度和通道数量, $(C_{l_j}^{out}, k_{l_j}, s_{l_j})$ 分别表示通道的值、内核大小和步幅大小;CNN网络主要由卷积层 l_j^c 和池化层 l_j^p 构成,将卷积层和池化层统一用 l_j 表示, l_j 层的总计算量记为 γ_{l_j} ,计算公式为:

$$\gamma_{l_j} = \begin{cases} 2 * H_{l_j} * W_{l_j} * (C_{l_j}^{in} * (k_{l_j})^2 + 1) * C_{l_j}^{out}, & l_j = l_j^c \\ H_{l_j} * W_{l_j} * C_{l_j}^{in}, & l_j = l_j^p \end{cases}$$

在CNN网络的推理过程中,前一层的输出作为下一层的输入,对于 l_j 层的输出量,等同于下一层 l_{j+1} 的输入量,所以输出的数据量记作 δ_{l_j} ,计算公式为:

$$\delta_{l_j} = W_{l_{j+1}} * H_{l_{j+1}} * C_{l_j}^{out} * \rho$$

其中, ρ 是单位数据的内存占用;

考虑每个MMD上的任一CNN网络只存在一个最优分割点,假设分割点为 p_i , i 表示第 i 个分区点,则本地执行第一层到第 p_i 层CNN网络,然后将执行 p_i 层后的中间数据卸载在MES上,MES通过执行 $p_i + 1$ 层一直到最后一层,最后把推断结果传输回MMD;当 $p_i = L_j$ 时,所有任务都在本地进行;当 $p_i = 0$ 时,任务直接卸载到MES上;

步骤232、获取CNN网络的计算延迟和传输延迟:

(1) MMD上的执行时间:令 F_m^{local} 表示设备 m 的计算资源,其中在时隙 t 内分配给设备 m 的本地执行应用的计算资源为 f_m^{local} , $f_m^{\text{local}} \leq F_m^{\text{local}}$;本地执行时间 $d_m^{\text{local}}(t)$ 为:

$$d_m^{\text{local}}(t) = \sum_{l_j=0}^{p_i^j} \frac{\gamma_{l_j, m}(t)}{f_m^{\text{local}}}$$

其中, $\sum_{l_j=0}^{p_i^j} \gamma_{l_j, m}(t)$ 表示在时隙 t 中设备 m 上,第一层和划分层 p_i^j 之间所有层的计算量之和, p_i^j 表示第 j 个CNN模型第 i 个分区点层数; $\gamma_{l_j, m}(t)$ 表示在时隙 t 中设备 m 上第 l_j 层的计算量;

(2) 中间输出数据的传输时间:

设备 $s \in S$ 到设备 $m \in M$ 之间通信链路的信道增益 $g_{m, s}$ 建模为:

$$g_{m, s} = \frac{g_0}{d_{m, s}^2}$$

其中, $d_{m, s}$ 表示对应设备间的欧氏距离, g_0 表示参考距离为1m时的信道增益;则对应的传输速率 $r_{m, s}^{\text{up}}$ 定义为:

$$r_{m, s}^{\text{up}} = B_{ul} \log_2 \left(1 + \frac{p_m^{\text{up}} g_{m, s}}{\sigma^2} \right)$$

其中, B_{ul} 为边缘计算网络的传输带宽, p_m^{up} 为无人机的传输功率, σ 为波导信道噪声;令 $\delta_{p_i^j, m}(t)$ 表示在 t 时隙期间设备 m 在分区层 p_i^j 传输的数据大小,得到设备 m 卸载到设备 s 的传输延迟 $d_{m, s}^{\text{up}}(t)$ 为:

$$d_{m, s}^{\text{up}}(t) = \frac{\delta_{p_i^j, m}(t)}{r_{m, s}^{\text{up}}}$$

考虑目标检测任务在MES的计算延迟以及多个任务之间的排队延迟;令 $f_{m, s}^{\text{edge}}$ 表示在时隙 t 内设备 $s \in S$ 分配给设备 $m \in M'$ 的计算资源,其中, $\sum_{m \in M'} f_{m, s}^{\text{edge}} \leq F_s^{\text{edge}}$, M' 为设备 s 同一时间提供计算服务的MMD设备集合, F_s^{edge} 为设备 s 的总计算资源;因此,计算出在 t 时隙,设备 m 在设备 s 上的执行延迟 $d_{m, s}^{\text{edge}}(t)$ 为:

$$d_{m, s}^{\text{edge}}(t) = \sum_{l_j=p_i^j+1}^{L_j} \frac{\gamma_{l_j, s}(t)}{f_{m, s}^{\text{edge}}}$$

其中, $\sum_{l_j=p_i^j+1}^{L_j} \gamma_{l_j, s}(t)$ 表示传输到设备 s 上的CNN网络分区在第 p_i^j 层后的部分的局部计算量; $\gamma_{l_j, s}(t)$ 表示在时隙 t 中设备 s 上第 l_j 层的计算量;

因此,在划分一个目标检测任务后,设备 m 的总执行时间 $d_m(t)$ 等于MMD上的本地执行时间、中间数据传输时间以及MES上的执行时间之和:

$$d_m(t) = d_m^{\text{local}}(t) + d_{m,s}^{\text{up}}(t) + d_{m,s}^{\text{edge}}(t)$$

假定每个 m 的每个任务必须在单个时隙时间内完成,即 $d_m(t) \leq \tau$;

步骤233、计算能量消耗:

(1) MMD上的执行能耗:假设 p_m^{local} 表示设备 m 的计算功率,则设备 m 本地执行能耗 $E_m^{\text{local}}(t)$ 为:

$$E_m^{\text{local}}(t) = p_m^{\text{local}} d_m^{\text{local}}(t)$$

(2) 设备 m 中间输出数据的传输能耗 $E_m^{\text{up}}(t)$ 为:

$$E_m^{\text{up}}(t) = p_m^{\text{up}} d_{m,s}^{\text{up}}(t)$$

其中, p_m^{up} 表示 m 的传输功率;

(3) 设备 m 执行任务所损耗的能耗为:

$$E_m^v(t) = p_m^v d_m(t)$$

其中, p_m^v 表示设备 m 执行任务时的平均功率;

(4) 当设备 m 执行部分CNN网络任务的总能量消耗 $E_m(t)$ 是本地执行能耗、中间输出数据的传输能耗以及执行任务所损耗的能耗之和:

$$E_m(t) = E_m^{\text{local}}(t) + E_m^{\text{up}}(t) + E_m^v(t)$$

步骤234、计算服务质量:

(1) 用 $u_{m,s}^e$ 和 $u_{m,s}^d$ 分别表示MMDs的能耗和时延的改善水平; $u_{m,s}^e$ 描述了通过计算卸载MMDs所节省的能源占当地能源消耗的比例, $u_{m,s}^d$ 表示通过MESs计算卸载,与本地延迟相比,时延的降低比例;因此,MMD的能耗和改善水平分别表示为:

$$u_{m,s}^e = \frac{E_m'(t) - E_m(t)}{E_m'(t)}$$

和

$$u_{m,s}^d = \frac{d_m'(t) - d_m(t)}{d_m'(t)}$$

其中, $d_m'(t)$ 和 $E_m'(t)$ 分别表示在时隙 t 期间设备 m 完全在本地执行任务时的延迟和能耗;

(2) 引入权重因子 $\omega_{m,s}$ 来衡量MMD在节能和延迟降低之间的权衡,考虑 MMD 的剩余电量,并将剩余电量比 E_m^{re} 进一步纳入权重因子,其中:

$$E_m^{\text{re}} = \frac{E_m^{\text{remain}}}{E_m^{\text{full}}}$$

其中, E_m^{remain} 和 E_m^{full} 分别表示设备的当前剩余电量和当前最大电池容量;

(3) 能耗改进和延迟改进的加权总和表示为:

$$f_{m,s} = \omega_{m,s} E_m^{\text{re}} u_{m,s}^d + (1 - \omega_{m,s} E_m^{\text{re}}) u_{m,s}^e$$

(4) 利用指数函数表征能耗改善和延迟改善的权衡模型与MMDs服务质量 $U_{m,s}^{\text{QoS}}$ 之间的映射关系, 定义为:

$$U_{m,s}^{\text{QoS}} = \alpha^{f_{m,s}-1}$$

其中, α 表示变量参数, $\alpha > 1$ 为正整数, 此时 $f_{m,s}$ 表示 α 的指数;

(5) 根据 $f_{m,s} = \omega_{m,s} E_m^{\text{re}} u_{m,s}^d + (1 - \omega_{m,s} E_m^{\text{re}}) u_{m,s}^e$ 推导出 $-\infty < f_{m,s} < 1$, 因此, 推导出 $U_{m,s}^{\text{QoS}}$ 的取值上界和下界分别为 $\alpha - 1$ 和 -1 ;

步骤235、定义目标问题:

调度策略主要包括根据MMD的剩余电池电量实时动态调整延迟和能耗的权重比, 并最小化系统延迟和能耗; 每个MMD通过决策 p_i^j 、 $f_{m,s}^{\text{edge}}$ 和 $o_{m,s}$ 来实施计算任务执行, 并优化系统中所有MMD的 $U_{m,s}^{\text{QoS}}$, 其中, $o_{m,s}$ 表示设备 m 选择设备 s 的决策, 如下所示:

$$\begin{aligned} \max_{\{p_i^j, f_{m,s}^{\text{edge}}, o_{m,s}\}} & \frac{1}{T} \sum_{t=1}^T \sum_{m \in M} \sum_{s \in S} U_{m,s}^{\text{QoS}}(t) \\ \text{s. t.} & \sum_{m \in M} f_{m,s}^{\text{edge}} \leq F_s^{\text{edge}} \\ & 0 \leq p_i^j \leq L_j \\ & 0 \leq o_{m,s} < |S| \\ & 0 \leq E_m^{\text{remain}} \leq E_m^{\text{full}} \end{aligned}$$

结合方程推断出目标问题是一个混合整数非线性规划问题, 也是一个非确定多项式-难问题;

约束 $\sum_{m \in M} f_{m,s}^{\text{edge}} \leq F_s^{\text{edge}}$ 表示设备 s 分配给设备 m 的计算资源不得超过最大可用本地计算资源; $0 \leq p_i^j \leq L_j$ 表示目标检测模型的分区点选择必须在目标检测模型的层数范围内; $0 \leq o_{m,s} < |S|$ 表示MMD对MESs的选择必须从集合 S 中选择, $0 \leq E_m^{\text{remain}} \leq E_m^{\text{full}}$ 表示MMD的剩余电池电量不超过其最大容量。

5. 如权利要求4所述的面向CNN网络的移动边缘计算动态卸载方法, 其特征在于, 所述步骤3具体包括:

步骤31、每个设备 m 被视为一个智能体, 将计算任务切分和资源分配问题进一步表示为一个多智能体马尔可夫决策过程, 并构建马尔可夫决策模型;

步骤32、根据环境状态自适应地确定每个设备的卸载决策, 以最大化用户服务质量; 将马尔可夫决策模型表示为 (S', A, P, R) , 其中, S' 是状态空间, A 是动作空间, P 是状态转移

概率矩阵, R 是奖励; 马尔可夫决策模型的状态、动作和奖励如下:

状态: 状态空间由 MMD 和 MES 的状态组成, 时隙 t 时刻的状态空间 S' 定义为 s_m :

$$s_m = \{l_m^{ta}, f_m^{local}, E_m^{remain}, f_{m,s}^{edge}, r_{m,s}^{up}\}$$

其中, l_m^{ta} 为时隙 t 时刻设备 m 上携带的 CNN 模型类别, f_m^{local} 表示在时隙 t 内分配给设备 m 的本地执行应用的计算资源, E_m^{remain} 表示 t 时隙时设备 m 的剩余电量, $f_{m,s}^{edge}$ 表示在时隙 t 内设备 $s \in S$ 分配给设备 $m \in M'$ 的计算资源, 通过广播的形式发送给每个 MMD;

$r_{m,s}^{up} = \{r_{m,1}^{up}, r_{m,2}^{up}, \dots, r_{m,|S|}^{up}\}$ 表示设备 m 与设备 S 之间的上行容量;

动作: 所有设备 m 的动作集是一个混合整数和非整数卸载决策向量, 设备 m 在时隙 t 的动作表示为:

$$a_m = \{o_{m,s}, p_i^j, f_{m,s}^{edge}\}$$

其中, $o_{m,s}$ 表示 MMD 卸载任务的卸载决策, p_i^j 表示 MMD 上携带的 CNN 网络的分区;

奖励: 在马尔可夫决策过程中, 奖励是指在时隙 t 的状态 s_m 下采取动作所获得的系统收益; 当设备 s 完成向设备 m 传输的任务时, 设备 m 生成服务质量 $U_{m,s}^{QoS}(t)$ 反馈, MESs 协作以实现所有设备的服务质量 $U_{m,s}^{QoS}(t)$ 最大化为目标; 因此, 奖励函数表示为:

$$R = \frac{1}{T} \sum_{t=1}^T \sum_{m \in M} \sum_{s \in S} s U_{m,s}^{QoS}(t)。$$

6. 如权利要求 5 所述的面向 CNN 网络的移动边缘计算动态卸载方法, 其特征在于, 所述步骤 4 具体包括:

步骤 41、基于网络节点保留算法进行网络切分节点确定:

(1) 选择一个 CNN 模型 j 作为预处理的目标, 计算不同带宽 B_k 下所有分区点对应的执行时间 $T_{p_i^j}$, $B_k \leq B_{ul}$; 定义 ζ 为保留分区层的集合; 定义 ζ_j^k 为带宽 B_k 对应的分区层集合; 定义 ζ_j 为当前 CNN 模型 j 对应的候选点集;

计算相同带宽 B_k 下所有分区点的平均执行时间 T_{avg}^j , 如下式所示:

$$T_{avg}^j = \sum_{p_i=1}^{L_j} T_{p_i^j} / L_j$$

(2) 令 ψ 为一个在 $[0, 1]$ 范围内的权重因子, 将每个节点与平均执行时间和权重因子 ψ 的乘积进行比较; 如果 $T_{p_i^j}$ 小于 ψT_{avg}^j , 则保留该节点至 ζ_j^k ; 否则, 消除该节点; 最后获得带宽 B_k 对应的 ζ_j^k ;

(3) 通过公式:

$$\zeta_j = \zeta_j \cap \zeta_j^k$$

更新 ζ_j , 当取不同的 B_k 值时, 重复步骤 41 中的 (1) ~ (3), 直至遍历所有的带宽 B_k , 获得最

终的 ζ_j ;

(4) 将所有类型CNN模型的候选点集 ζ_j 整合到 ζ 中;

步骤42、基于多智能体深度强化学习算法进行联合优化策略:

(1) 在多智能体协作环境中集成了MADDPG框架,每个智能体由一个演员网络 μ 和一个评论家网络 Q 组成,两者都由深度神经网络参数化;演员网络以状态观察为输入,并根据策略 π 输出动作;同时,评论家网络使用状态-动作函数 $Q(s, a)$ 根据当前状态评估演员网络选择的动作;

(2) 在MADDPG框架中,每个目标网络以多个智能体的全局状态为输入,以评估这些状态下动作的质量;目标网络通过生成暂时延迟的目标策略和价值估计来促进稳定学习;在MADDPG框架中,演员网络根据其本地智能体观察状态 s_m 确定本地动作 a_m ,每个智能体的策略参数定义为 $\theta = [\theta_1, \theta_2, \dots, \theta_{|M|}]$,其中, θ_m 表示第 m 个智能体的策略参数,每个智能体采用由 θ_m^μ 参数化的连续策略 μ_m^θ , θ_m^μ 为智能体 m 的演员网络参数;在确定性策略框架下,每个智能体采用连续策略 $a_m = \mu_m^\theta(s_m | \theta_m^\mu) + N$,其中 N 是用于增强系统探索能力的随机噪声;

(3) 评论家网络将智能体的状态 s_m 和动作 a_m 作为输入,表示为 $Q_m(s_m, a_m | \theta_m^Q)$,其中, θ_m^Q 为评论家网络的网络参数,评论家网络用于对集体性能 $Q_m(s_m, a_m)$ 进行全局评估,其输入包括所有智能体的动作和状态;智能体的目标演员网络定义为 μ_m' ,对应的网络参数定义为 $\theta_m^{\mu'}$,目标网络表示为 Q' ,对应的网络参数为 $\theta_m^{Q'}$;这些参数的更新公式定义为:

$$\begin{cases} \theta_m^{\mu'} \leftarrow \eta \theta_m^{\mu'} + (1-\eta) \theta_m^{\mu} \\ \theta_m^{Q'} \leftarrow \eta \theta_m^{Q'} + (1+\eta) \theta_m^{Q'} \end{cases}$$

其中,参数 η 表示一个在0到1范围内的系数;

(4) MADDPG算法包括两个阶段:集中离线训练和分散执行;

在集中离线训练过程中,系统收集智能体的状态信息 $[s_m, a_m, r_m, s'_m]$,其中 s'_m 表示状态为 s_m 时执行动作 a_m 后进入的下一个状态,此状态信息存储在经验回放缓冲区中; $r_m = \sum_{s \in s} u_{m,s}^{QoS}(t)$ 是当前动作获得的奖励值;在将数据收集到经验回放缓冲区后,随机采样用于策略评估过程;MADDPG算法遵循离线策略方法,使用采样数据更新 Q 和 μ 的参数;目标函数更新表示为:

$$y_m = r_m + \phi Q'(s'_m, a'_m | \theta_m^{Q'}) |_{a'_m = \mu'_m(s'_m)}$$

其中, ϕ 表示折扣因子, a'_m 是通过公式: $a'_m = \mu'_m(s'_m)$ 得到,通过最小化损失函数来更新评论家网络:

$$L(\theta_m^Q) = E[Q(s_m, a_m | \theta_m^Q) - y_m]^2$$

其中, $E[\cdot]$ 表示求期望;

在更新评论家网络后,演员网络通过以下公式进行参数 θ_m^μ 的更新:

$$\nabla_{\theta_m^Q} L(\theta_m^Q) = E[2(y_m - Q(s_m, a_m | \theta_m^Q)) \nabla_{\theta_m^Q} (Q(s_m, a_m))]$$

其中, $\nabla_{\theta_m^Q}$ 表示参数 θ_m^Q 的梯度;

然后,评论家网络根据神经网络的梯度规则更新其参数,得到:

$$\theta_m^Q \leftarrow \theta_m^Q - \varepsilon \nabla_{\theta_m^Q} L(\theta_m^Q)$$

其中, ε 为评论家网络的学习率,然后,利用策略梯度法对演员网络进行更新,得到:

$$\nabla_{\theta_m^\mu} \mu = \nabla_{a_m} Q(s_m, a_m | \theta_m^Q) \Big|_{(s_m=S^*, a_m=\mu_m^Q(s_m | \theta_m^\mu))} \nabla_{\theta_m^\mu} \mu(s_m | \theta_m^\mu)$$

演员网络参数更新为:

$$\theta_m^\mu \leftarrow \theta_m^\mu + \beta \nabla_{\theta_m^\mu} \mu$$

其中, β 为评论家网络的学习率; μ 表示演员网络; $\nabla_{\theta_m^\mu} \mu$ 表示对演员网络 μ 求关于参数 θ_m^μ 的梯度;

步骤43、多智能体深度强化学习算法的标准化和自适应学习率:

(1) 在多智能体深度强化学习算法的初始化过程中,通过在临时内存中存储训练期间的最大值和最小值并计算缩放因子来对环境状态进行标准化,每个环境变量的最大值和最小值之差作为缩放因子;通过从当前状态中减去最小值并除以获得的缩放因子,得到标准化的状态信息;

(2) 在强化学习的训练过程中,采用衰减学习率策略根据不同训练阶段的损失率调整学习率的大小:

$$\begin{cases} \varepsilon \leftarrow \varepsilon * \omega \\ \beta \leftarrow \beta * \omega \end{cases}$$

其中, ω 是学习率衰减系数。

7. 如权利要求1所述的面向CNN网络的移动边缘计算动态卸载方法,其特征在于,所述步骤6具体包括:

步骤61、通感算一体化系统获得实时的网络状态数据和设备状态数据,感知设备根据用户需求获得实时的图像任务数据;

步骤62、基于输入的网络状态数据、设备状态数据和图像任务数据,根据神经网络所确定的多智能体马尔可夫决策模型,产生计算任务的切分和计算资源的分配决策;

步骤63、将决策结果信息同步至通感算一体化系统中各节点;

步骤64、各节点实施执行具体的计算任务。

8. 一种电子设备,包括存储器、处理器及存储在存储器上并可在处理器上运行的计算机程序,其特征在于,所述处理器执行所述程序时实现如权利要求1至7任一项所述的面向CNN网络的移动边缘计算动态卸载方法。

9. 一种计算机可读存储介质,其上存储有计算机程序,其特征在于,该程序被处理器执行时实现如权利要求1至7任一项所述的面向CNN网络的移动边缘计算动态卸载方法。

面向CNN网络的移动边缘计算动态卸载方法及设备介质

技术领域

[0001] 本发明涉及计算和通信技术领域,尤其涉及一种面向CNN网络的移动边缘计算动态卸载方法及设备介质。

背景技术

[0002] 随着智能终端在物联网中各类应用场景的普及,基于卷积神经网络(CNN)技术的计算密集型和时延敏感型业务(如海洋观测和监测,森林防火与预警,海洋资源勘测与开发等)对计算能力的需求不断提高。然而,受物理空间、成本和能耗限制,终端设备的本地计算资源难以满足高计算需求海洋应用。移动边缘计算(MEC)利用边缘服务器(MESs)的计算资源来降低移动设备的计算负载,成为一种可行的解决方案。受限于成本导致的设备稀疏部署,MES的计算和缓存资源有限且分布不均匀。随着移动设备(MMDs)的数量和计算需求的增加,MES面临高超载风险并导致QoS无法保证。因此,在实际的应用场景中,考虑到搭载在智能移动设备上CNN任务的异构性,CNN网络结构的串行性,在多个MESs之间的动态的调度与资源分配,提供最佳的部分卸载决策,以应对动态的MMEC环境,显得尤为必要。

[0003] CNN计算任务的网络结构依赖性,使其卸载决策面临比传统任务更复杂的实际应用挑战。融合地面和空中资源的混合边缘计算方案,基于雾的三层边缘计算架构方案等基于分层的多接入边缘计算策略,有助于提高动态的MMEC中数据传输和计算任务执行的质量。然而,该类基于高度抽象化计算任务的策略,难以满足具体的计算部署需求。例如,CNN的细粒度分区卸载研究表明,细致的网络分区可提供更多卸载选项,有助于寻找系统最优解并加速模型推理过程。CNN网络的分区点确定方法包括构建自适应神经网络模型,建立代价矩阵或使用深度学习推理延迟模型,通过神经网络枚举合适的分区点。特别地,针对大型CNN图像目标检测模型,提出了一种基于遗传算法的卸载策略,将模型各层视为卸载候选点,并通过遗传搜索机制寻找最优卸载配置。

[0004] 尽管CNN卸载策略的研究已经取得了一定的进展,但在动态且资源受限的移动物联网环境中,环境因素、设备计算资源异构和移动设备间的资源竞争对CNN计算任务带来卸载决策优化和计算质量保障方面的挑战。由于MEC面临数据传输受到通信不稳定导致数据丢失,导致CNN网络的水平划分策略因存在设备间频繁交换数据而难以适用。此外,随着海上设备网络结构和类型的多样化,优化卸载策略的复杂性随之增加。

发明内容

[0005] 有鉴于此,本发明的目的在于提出一种面向CNN网络的移动边缘计算动态卸载方法,对计算和通信资源缺乏且网络环境动态的边缘计算任务场景中,基于CNN网络架构的高计算资源消耗任务,制定动态的计算卸载策略,从而实现在不确定的网络环境中和网络资源紧缺的条件下,实现计算任务的顺利执行。

[0006] 为了实现上述的技术目的,本发明所采用的技术方案为:

[0007] 本发明提供了一种面向CNN网络的移动边缘计算动态卸载方法,包括如下步骤:

[0008] 步骤1、根据目标检测需求,在通感算一体化系统中获取图像任务数据、设备状态数据和网络状态数据,构成数据集;

[0009] 步骤2、基于通感算一体化系统和数据集,构建通感算一体化系统模型,面向计算任务,将通感算一体化系统模型转化为计算任务切分和资源分配问题;

[0010] 步骤3、基于通感算一体化系统模型和计算任务切分和资源分配问题,构建马尔可夫决策模型;

[0011] 步骤4、基于马尔可夫决策模型和多智能体深度强化学习算法得到联合优化策略,通过数据集进行训练,获得满足终止条件的神经网络参数模型;

[0012] 步骤5、将训练好的神经网络参数模型部署到通感算一体化系统中;

[0013] 步骤6、根据实时的图像任务数据、设备状态数据和网络状态数据,产生计算任务切分决策和计算资源分配决策,并将决策结果信息传输至通感算一体化系统的各节点,最终实现计算任务的卸载。

[0014] 进一步的,所述步骤1具体包括:

[0015] 步骤11、根据用户提交的任务需求,所述通感算一体化系统由多个移动设备和感知设备构成;通感算一体化系统中的感知设备执行数据感知操作,采集并存储图像任务数据;通感算一体化系统同时记录移动设备的设备状态数据和网络状态数据;

[0016] 步骤12、基于时隙对获取到的图像任务数据、设备状态数据和网络状态数据进行划分,形成设定时间段内的时序数据集;所述时隙是指具有设定时间长度的时间段,在该时间段内获取的数据均标记为该时隙的数据,所述时序数据是指具有时隙属性且按照时隙顺序编号的数据;

[0017] 步骤13、将所述时序数据集划分为训练集、验证集和检测集。

[0018] 进一步的,所述步骤2具体包括:

[0019] 步骤21、通感算一体化系统中具有感知、计算、通信和存储功能的节点通过无线和有线通信的方式或者仅无线的方式相互连接,组成通感算一体化系统模型;所述通感算一体化系统模型按照步骤12中所划分的时隙工作;

[0020] 步骤22、在基于时隙划分的通感算一体化系统模型中,用户在某一时隙发起任务请求;具体为:

[0021] 在基于时隙划分的通感算一体化系统模型中,移动设备MMDs的集合 $\mathbf{M} = \{1, \dots, m, \dots, |\mathbf{M}|\}$,其中,设备m表示在多个移动设备MMDs中选择某一个移动设备MMD,实施任务感知,且均装载了基于CNN网络的计算模块,所述CNN网络包含多个CNN模型,不同的CNN模型对应不同的计算任务;边缘服务器MESs的集合 $\mathbf{S} = \{1, \dots, s, \dots, |\mathbf{S}|\}$,其中,设备s表示在多个边缘服务器MESs中选择某一个边缘服务器MES,为周围的移动设备MMDs提供计算资源;设备间通过有线及无线或仅无线的方式组成通感算一体的网络,用户终端通过有线或无线的方式接入该通感算一体的网络,并在某一时隙向该通感算一体的网络发起任务请求;所述请求包含要感知的数据类型和所要求的数据处理要求;

[0022] 步骤23、通感算一体化系统模型接收到该任务请求后,实施感知和计算过程;所述计算过程由数据传输和数据处理组成,所述感知和计算过程为通感算一体化过程;具体为:

[0023] 移动设备MMDs负责计算卸载决策的实施,首先,移动设备MMDs选择其中一个设备

$s \in S$ 建立通信,将部分工作负载卸载到MES上;整个通感算一体化系统模型以时隙的方式运行,将 T 作为通感算一体化系统整个运行时间,把整个运行时间划分为 T 个长度相等的时隙,则时隙持续时间表示为 $\tau = \lfloor (T/T) \rfloor$, $\lfloor \cdot \rfloor$ 表示向下取整,MMDs在时隙 $t \in \{1, 2, \dots, T\}$ 开始时执行一个目标检测任务;具体的步骤如下:在每个时隙 t 开始时,设备 $m \in M$ 根据用户的提交的需求而生成不同的目标检测任务,不同类别任务所需的CNN模型是异构的,设备 $m \in M$ 需要选择合适的设备 $s \in S$ 建立联系并确定任务卸载部分,每个 $s \in S$ 收到多个 $m \in M$ 的请求并为其分配计算资源。

[0024] 进一步的,所述步骤23具体包括:

[0025] 步骤231、根据CNN网络对任务进行分区卸载:

[0026] 假定通感算一体化系统一共有 J 种CNN模型,对于第 j 个CNN模型,其中, $1 \leq j \leq J$,用 L_j 表示第 j 个CNN模型的总层数,第 j 个CNN模型每一层 l_j 的属性为 $(H_{l_j}, W_{l_j}, C_{l_j}^{in}, C_{l_j}^{out}, k_{l_j}, s_{l_j})$,其中, $1 \leq l_j \leq L_j$, $(H_{l_j}, W_{l_j}, C_{l_j}^{in})$ 分别表示 l_j 输入的高度、宽度和通道数量, $(C_{l_j}^{out}, k_{l_j}, s_{l_j})$ 分别表示通道的值、内核大小和步幅大小;CNN网络主要由卷积层 l_j^c 和池化层 l_j^p 构成,将卷积层和池化层统一用 l_j 表示, l_j 层的总计算量记为 γ_{l_j} ,计算公式为:

$$[0027] \quad \gamma_{l_j} = \begin{cases} 2 * H_{l_j} * W_{l_j} * (C_{l_j}^{in} * (k_{l_j})^2 + 1) * C_{l_j}^{out}, & l_j = l_j^c \\ H_{l_j} * W_{l_j} * C_{l_j}^{in}, & l_j = l_j^p \end{cases}$$

[0028] 在CNN网络的推理过程中,前一层的输出作为下一层的输入,对于 l_j 层的输出量,等同于下一层 l_{j+1} 的输入量,所以输出的数据量记作 δ_{l_j} ,计算公式为:

$$[0029] \quad \delta_{l_j} = W_{l_{j+1}} * H_{l_{j+1}} * C_{l_j}^{out} * \varrho$$

[0030] 其中, ϱ 是单位数据的内存占用;

[0031] 考虑每个MMD上的任一CNN网络只存在一个最优分割点,假设分割点为 p_i , i 表示第 i 个分区点,则本地执行第一层到第 p_i 层CNN网络,然后将执行 p_i 层后的中间数据卸载在MES上,MES通过执行 $p_i + 1$ 层一直到最后一层,最后把推断结果传输回MMD;当 $p_i = L_j$ 时,所有任务都在本地进行;当 $p_i = 0$ 时,任务直接卸载到MES上;

[0032] 步骤232、获取CNN网络的计算延迟和传输延迟:

[0033] (1) MMD上的执行时间:令 F_m^{local} 表示设备 m 的计算资源,其中在时隙 t 分配给本地执行应用的计算资源为 f_m^{local} , $f_m^{local} \leq F_m^{local}$;本地执行时间 $d_m^{local}(t)$ 为:

$$[0034] \quad d_m^{local}(t) = \sum_{l_j=0}^{p_i^j} \frac{\gamma_{l_j, m}(t)}{f_m^{local}}$$

[0035] 其中, $\sum_{l_j=0}^{p_i^j} \gamma_{l_j, m}(t)$ 表示在时隙 t 中设备 m 上,第一层和划分层 p_i^j 之间所有层的

计算量之和, p_i^j 表示第 j 个 CNN 模型第 i 个分区点层数; $\gamma_{l_j, m}(t)$ 表示在时隙 t 中设备 m 上第 l_j 层的计算量;

[0036] (2) 中间输出数据的传输时间:

[0037] 设备 $s \in \mathbf{S}$ 到设备 $m \in \mathbf{M}$ 之间通信链路的信道增益 $g_{m, s}$ 建模为:

$$[0038] \quad g_{m, s} = \frac{g_0}{d_{m, s}^2}$$

[0039] 其中, $d_{m, s}$ 表示对应设备间的欧氏距离, g_0 表示参考距离为 1m 时的信道增益; 则对应的传输速率 $r_{m, s}^{up}$ 定义为:

$$[0040] \quad r_{m, s}^{up} = B_{ul} \log_2 \left(1 + \frac{p_m^{up} g_{m, s}}{\sigma^2} \right)$$

[0041] 其中, B_{ul} 为边缘计算网络的传输带宽, p_m^{up} 为无人机的传输功率, σ 为波导信道噪声; 令 $\delta_{p_i^j, m}(t)$ 表示在 t 时隙期间设备 m 在分区层 p_i^j 传输的数据大小, 得到设备 m 卸载到设备 s 的传输延迟 $d_{m, s}^{up}(t)$ 为:

$$[0042] \quad d_{m, s}^{up}(t) = \frac{\delta_{p_i^j, m}(t)}{r_{m, s}^{up}}$$

[0043] 考虑目标检测任务在 MES 的计算延迟以及多个任务之间的排队延迟; 令 $f_{m, s}^{edge}$ 表示在 t 时隙内设备 $s \in \mathbf{S}$ 分配给设备 $m \in \mathbf{M}'$ 的计算资源, 其中, $\sum_{m \in \mathbf{M}'} f_{m, s}^{edge} \leq F_s^{edge}$, $\mathbf{M}'$ 为设备 s 同一时间提供计算服务的 MMD 设备集合, F_s^{edge} 为设备 s 的总计算资源; 因此, 计算出在 t 时隙, 设备 m 在设备 s 上的执行延迟 $d_{m, s}^{edge}(t)$ 为:

$$[0044] \quad d_{m, s}^{edge}(t) = \sum_{l_j=p_i^j+1}^{L_j} \frac{\gamma_{l_j, s}(t)}{f_{m, s}^{edge}}$$

[0045] 其中, $\sum_{l_j=p_i^j+1}^{L_j} \gamma_{l_j, s}(t)$ 表示传输到设备 s 上的 CNN 网络分区在第 p_i^j 层后的部分的局部计算量; $\gamma_{l_j, s}(t)$ 表示在时隙 t 中设备 s 上第 l_j 层的计算量;

[0046] 因此, 在划分一个目标检测任务后, 设备 m 的总执行时间 $d_m(t)$ 等于 MMD 上的本地执行时间、中间数据传输时间以及 MES 上的执行时间之和:

$$[0047] \quad d_m(t) = d_m^{local}(t) + d_{m, s}^{up}(t) + d_{m, s}^{edge}(t)$$

[0048] 假定每个 m 的每个任务必须在单个时隙时间内完成, 即 $d_m(t) \leq \tau$;

[0049] 步骤 233、计算能量消耗:

[0050] (1) MMD 上的执行能耗: 假设 p_m^{local} 表示设备 m 的计算功率, 则设备 m 本地执行能耗

$E_m^{local}(t)$ 为:

$$[0051] \quad E_m^{local}(t) = p_m^{local} d_m^{local}(t)$$

[0052] (2) 设备 m 中间输出数据的传输能耗 $E_m^{up}(t)$ 为:

$$[0053] \quad E_m^{up}(t) = p_m^{up} d_m^{up}(t)$$

[0054] 其中, p_m^{up} 表示 m 的传输功率;

[0055] (3) 设备 m 执行任务所损耗的能耗为:

$$[0056] \quad E_m^v(t) = p_m^v d_m^v(t)$$

[0057] 其中, p_m^v 表示设备 m 执行任务时的平均功率;

[0058] (4) 当设备 m 执行部分CNN网络任务的总能量消耗 $E_m(t)$ 是本地执行能耗、中间输出数据的传输能耗以及执行任务所损耗的能耗之和:

$$[0059] \quad E_m(t) = E_m^{local}(t) + E_m^{up}(t) + E_m^v(t)$$

[0060] 步骤234、计算服务质量:

[0061] (1) 用 $u_{m,s}^e$ 和 $u_{m,s}^d$ 分别表示MMDs的能耗和时延的改善水平; $u_{m,s}^e$ 描述了通过计算卸载MMDs所节省的能源占当地能源消耗的比例, $u_{m,s}^d$ 表示通过MESs计算卸载,与本地延迟相比,时延的降低比例;因此,MMD的能耗和改善水平分别表示为:

$$[0062] \quad u_{m,s}^e = \frac{E_m'(t) - E_m(t)}{E_m'(t)}$$

[0063] 和

$$[0064] \quad u_{m,s}^d = \frac{d_m'(t) - d_m(t)}{d_m'(t)}$$

[0065] 其中, $d_m'(t)$ 和 $E_m'(t)$ 分别表示在时隙 t 期间设备 m 完全在本地执行任务时的延迟和能耗;

[0066] (2) 引入权重因子 $\omega_{m,s}$ 来衡量MMD在节能和延迟降低之间的权衡,考虑 MMD 的剩余电池电量,并将剩余电量比 E_m^{re} 进一步纳入权重因子,其中:

$$[0067] \quad E_m^{re} = \frac{E_m^{remain}}{E_m^{full}}$$

[0068] 其中, E_m^{remain} 和 E_m^{full} 分别表示设备的当前最大电池容量和当前剩余电量;

[0069] (3) 能耗改进和延迟改进的加权总和表示为:

$$[0070] \quad f_{m,s} = \omega_{m,s} E_m^{re} u_{m,s}^d + (1 - \omega_{m,s} E_m^{re}) u_{m,s}^e$$

[0071] (4) 利用指数函数表征能耗改善和延迟改善的权衡模型与MMDs服务质量 $U_{m,s}^{QoS}$ 之间的映射关系,定义为:

$$[0072] \quad U_{m,s}^{QoS} = a f_{m,s} - 1$$

[0073] 其中, α 表示变量参数, $\alpha > 1$ 为正整数, 此时 $f_{m,s}$ 表示 α 的指数;

[0074] (5) 根据 $f_{m,s} = \omega_{m,s} E_m^{\alpha} u_{m,s}^d + (1 - \omega_{m,s} E_m^{\alpha}) u_{m,s}^e$ 推导出 $-\infty < f_{m,s} < 1$, 因此, 推导出 $u_{m,s}^{QoS}$ 的取值上界和下界分别为 $\alpha - 1$ 和 -1 ;

[0075] 步骤235、定义目标问题:

[0076] 调度策略主要包括根据MMD的剩余电池电量实时动态调整延迟和能耗的权重比, 并最小化系统延迟和能耗; 每个MMD通过决策 p_i^j 、 $f_{m,s}^{edge}$ 和 $o_{m,s}$ 来实施计算任务执行, 并优化系统中所有MMD的 $u_{m,s}^{QoS}$, 其中, $o_{m,s}$ 表示设备 m 选择设备 s 的决策, 如下所示:

$$[0077] \quad \max_{\{p_i^j, f_{m,s}^{edge}, o_{m,s}\}} \frac{1}{T} \sum_{t=1}^T \sum_{m \in M} \sum_{s \in S} u_{m,s}^{QoS}(t)$$

$$[0078] \quad \text{s. t.} \quad \sum_{m \in M'} f_{m,s}^{edge} \leq F_s^{edge}$$

$$[0079] \quad 0 \leq p_i^j \leq L_j$$

$$[0080] \quad 0 \leq o_{m,s} < |S|$$

$$[0081] \quad 0 \leq E_m^{remain} \leq E_m^{full}$$

[0082] 结合方程推断出目标问题是一个混合整数非线性规划问题, 也是一个非确定多项式-难问题;

[0083] 约束 $\sum_{m \in M'} f_{m,s}^{edge} \leq F_s^{edge}$ 表示设备 s 分配给设备 m 的计算资源不得超过最大可用本地计算资源; $0 \leq p_i^j \leq L_j$ 表示目标检测模型的分区点选择必须在目标检测模型的层数范围内; $0 \leq o_{m,s} < |S|$ 表示MMD对MESs的选择必须从集合 S 中选择, $0 \leq E_m^{remain} \leq E_m^{full}$ 表示MMD的剩余电池电量不超过其最大容量。

[0084] 进一步的, 所述步骤3具体包括:

[0085] 步骤31、每个设备 m 被视为一个智能体, 将计算任务切分和资源分配问题进一步表示为一个多智能体马尔可夫决策过程, 并构建马尔可夫决策模型;

[0086] 步骤32、根据环境状态自适应地确定每个设备的卸载决策, 以最大化用户服务质量; 将马尔可夫决策模型表示为 (S', A, P, R) , 其中, S' 是状态空间, A 是动作空间, P 是状态转移概率矩阵, R 是奖励; 马尔可夫决策模型的状态、动作和奖励如下:

[0087] 状态: 状态空间由MMD和MES的状态组成, 时隙 t 时刻的状态空间 S' 定义为 s_m :

$$[0088] \quad s_m = \{l_m^{ta}, f_m^{local}, E_m^{remain}, f_{m,s}^{edge}, r_{m,s}^{up}\}$$

[0089] 其中, l_m^{ta} 为时隙 t 时刻设备 m 上携带的CNN模型类别, f_m^{local} 表示在时隙 t 内分配给设备 m 的本地执行应用的计算资源, E_m^{remain} 表示 t 时隙时设备 m 的剩余电量, $f_{m,s}^{edge}$ 表示在 t 时隙内设备 $s \in S$ 分配给设备 $m \in M'$ 的计算资源, 通过广播的形式发送给每个MMD;

$r_{m,s}^{up} = \{r_{m,1}^{up}, r_{m,2}^{up}, \dots, r_{m,|S|}^{up}\}$ 表示设备m与设备s之间的上行容量;

[0090] 动作:所有设备m的动作集是一个混合整数和非整数卸载决策向量,设备m在时隙t的动作表示为:

$$[0091] \quad a_m = \{o_{m,s}, p_i^j, f_{m,s}^{edge}\}$$

[0092] 其中, $o_{m,s}$ 表示MMD卸载任务的卸载决策, p_i^j 表示MMD上携带的CNN网络的分区;

[0093] 奖励:在马尔可夫决策过程中,奖励是指在时隙t的状态 s_m 下采取动作所获得的系统收益;当设备s完成向设备m传输的任务时,设备m生成服务质量 $u_{m,s}^{QoS}(t)$ 反馈, MESs协作以实现所有设备的服务质量 $u_{m,s}^{QoS}(t)$ 最大化为目标;因此,奖励函数表示为:

$$[0094] \quad R = \frac{1}{T} \sum_{t=1}^T \sum_{m \in M} \sum_{s \in S} u_{m,s}^{QoS}(t)。$$

[0095] 进一步的,所述步骤4具体包括:

[0096] 步骤41、基于网络节点保留算法进行网络切分节点确定:

[0097] (1) 选择一个CNN模型j作为预处理的的目标,计算不同带宽 B_k 下所有分区点对应的执行时间 $T_{p_i^j}$, $B_k \leq B_{ul}$; 定义 ζ 为保留分区层的集合; 定义 ζ_j^k 为带宽 B_k 对应的分区层集合; 定义 ζ_j 为当前CNN模型j对应的候选点集;

[0098] 计算相同带宽 B_k 下所有分区点的平均执行时间 T_{avg}^j , 如下式所示:

$$[0099] \quad T_{avg}^j = \sum_{p_i^j=1}^{L_j} T_{p_i^j} / L_j$$

[0100] (2) 令 ψ 为一个在 $[0, 1]$ 范围内的权重因子,将每个节点与平均执行时间和权重因子 ψ 的乘积进行比较;如果 $T_{p_i^j}$ 小于 ψT_{avg}^j , 则保留该节点至 ζ_j^k ; 否则,消除该节点;最后获得带宽 B_k 对应的 ζ_j^k ;

[0101] (3) 通过公式:

$$[0102] \quad \zeta_j = \zeta_j \cap \zeta_j^k$$

[0103] 更新 ζ_j , 当取不同的 B_k 值时,重复步骤41中的(1)~(3),直至遍历所有的带宽 B_k , 获得最终的 ζ_j ;

[0104] (4) 将所有类型CNN模型的候选点集 ζ_j 整合到 ζ 中;

[0105] 步骤42、基于多智能体深度强化学习算法进行联合优化策略:

[0106] (1) 在多智能体协作环境中集成了MADDPG框架,每个智能体由一个演员网络 μ 和一个评论家网络 Q 组成,两者都由深度神经网络参数化;演员网络以状态观察为输入,并根据策略 π 输出动作;同时,评论家网络使用状态-动作函数 $Q(s, a)$ 根据当前状态评估演员网络选择的动作;

[0107] (2) 在MADDPG框架中,每个目标网络以多个智能体的全局状态为输入,以评估这些状态下动作的质量;目标网络通过生成暂时延迟的目标策略和价值估计来促进稳定学习;在MADDPG框架中,演员网络根据其本地智能体观察状态 s_m 确定本地动作 a_m ,每个智能体的策略参数定义为 $\theta = [\theta_1, \theta_2, \dots, \theta_M]$,其中, θ_m 表示第 m 个智能体的策略参数,每个智能体采用由 θ_m^μ 参数化的连续策略 μ_m^θ , θ_m^μ 为智能体 m 的演员网络参数;在确定性策略框架下,每个智能体采用连续策略 $a_m = \mu_m^\theta(s_m | \theta_m^\mu) + N$,其中 N 是用于增强系统探索能力的随机噪声;

[0108] (3) 评论家网络将智能体的状态 s_m 和动作 a_m 作为输入,表示为 $Q_m(s_m, a_m | \theta_m^Q)$,其中, θ_m^Q 为评论家网络的网络参数,评论家网络用于对集体性能 $Q_m(s_m, a_m)$ 进行全局评估,其输入包括所有智能体的动作和状态;智能体的目标演员网络定义为 μ_m' ,对应的网络参数定义为 $\theta_m^{\mu'}$,目标网络表示为 Q' ,对应的网络参数为 $\theta_m^{Q'}$;这些参数的更新公式定义为:

$$[0109] \quad \begin{cases} \theta_m^{\mu'} \leftarrow \eta \theta_m^{\mu'} + (1-\eta) \theta_m^{\mu} \\ \theta_m^{Q'} \leftarrow \eta \theta_m^{Q'} + (1+\eta) \theta_m^{Q'} \end{cases}$$

[0110] 其中,参数 η 表示一个在0到1范围内的系数;

[0111] (4) MADDPG算法包括两个阶段:集中离线训练和分散执行;

[0112] 在集中离线训练过程中,系统收集智能体的状态信息 $[s_m, a_m, r_m, s'_m]$,其中 s'_m 表示状态为 s_m 时执行动作 a_m 后进入的下一个状态,此状态信息存储在经验回放缓冲区中; $r_m = \sum_{s \in s} s U_{m,s}^{QoS}(t)$ 是当前动作获得的奖励值;在将数据收集到经验回放缓冲区后,随机采样用于策略评估过程;MADDPG算法遵循离线策略方法,使用采样数据更新 Q 和 μ 的参数;目标函数更新表示为:

$$[0113] \quad y_m = r_m + \gamma Q'(s'_m, a'_m | \theta_m^{Q'}) |_{a'_m = \mu'_m(s'_m)}$$

[0114] 其中, γ 表示折扣因子, a'_m 是通过公式: $a'_m = \mu'_m(s'_m)$ 得到,通过最小化损失函数来更新评论家网络:

$$[0115] \quad L(\theta_m^Q) = E[Q(s_m, a_m | \theta_m^Q) - y_m]^2$$

[0116] 其中, $E[\cdot]$ 表示求期望;

[0117] 在更新评论家网络后,演员网络通过以下公式进行参数 θ_m^μ 的更新:

$$[0118] \quad \nabla_{\theta_m^Q} L(\theta_m^Q) = E[2(y_m - Q(s_m, a_m | \theta_m^Q)) \nabla_{\theta_m^Q} (Q(s_m, a_m))]$$

[0119] 其中, $\nabla_{\theta_m^Q}$ 表示参数 θ_m^Q 的梯度;

[0120] 然后,评论家网络根据神经网络的梯度规则更新其参数,得到:

$$[0121] \quad \theta_m^Q \leftarrow \theta_m^Q - \varepsilon \nabla_{\theta_m^Q} L(\theta_m^Q)$$

[0122] 其中, ε 为评论家网络的学习率,然后,利用策略梯度法对演员网络进行更新,得

到:

$$[0123] \quad \nabla_{\theta_m^{\mu}} \mu = \nabla_{a_m} Q(s_m, a_m | \theta_m^Q) \Big|_{s=s_m, a_m=\mu_m^{\theta}(s_m | \theta_m^{\mu})} \nabla_{\theta_m^{\mu}} \mu(s_m | \theta_m^{\mu})$$

[0124] 演员网络参数更新为:

$$[0125] \quad \theta_m^{\mu} \leftarrow \theta_m^{\mu} + \beta \nabla_{\theta_m^{\mu}} \mu$$

[0126] 其中, β 为评论家网络的学习率; μ 表示演员网络; $\nabla_{\theta_m^{\mu}} \mu$ 表示对演员网络 μ 求关于参数 θ_m^{μ} 的梯度;

[0127] 步骤43、多智能体深度强化学习算法的标准化和自适应学习率:

[0128] (1) 在多智能体深度强化学习算法的初始化过程中,通过在临时内存中存储训练期间的最大值和最小值并计算缩放因子来对环境状态进行标准化,每个环境变量的最大值和最小值之差作为缩放因子;通过从当前状态中减去最小值并除以获得的缩放因子,得到标准化的状态信息;

[0129] (2) 在强化学习的训练过程中,采用衰减学习率策略根据不同训练阶段的损失率调整学习率的大小:

$$[0130] \quad \begin{cases} \varepsilon \leftarrow \varepsilon * \varpi \\ \beta \leftarrow \beta * \varpi \end{cases}$$

[0131] 其中, ϖ 是学习率衰减系数。

[0132] 进一步的,所述步骤5具体包括:

[0133] 步骤51、根据环境动态信息,以设定的时间间隔,将训练好的神经网络参数同步至CNN网络中每个节点;所述时间间隔取决于新的神经网络参数训练过程是否收敛到新的状态;

[0134] 步骤52、CNN网络中各节点基于获得的神经网络参数更新卸载策略和资源分配策略;

[0135] 步骤53、CNN网络中各节点向通感算一体化系统反馈更新后的策略状态。

[0136] 进一步的,所述步骤6具体包括:

[0137] 步骤61、通感算一体化系统获得实时的网络状态数据和设备状态数据,感知设备根据用户需求获得实时的图像任务数据;

[0138] 步骤62、基于输入的网络状态数据、设备状态数据和图像任务数据,根据神经网络所确定的多智能体马尔可夫决策模型,产生计算任务的切分和计算资源的分配决策;

[0139] 步骤63、将决策结果信息同步至通感算一体化系统中各节点;

[0140] 步骤64、各节点实施执行具体的计算任务。

[0141] 本发明还提供了一种电子设备,包括存储器、处理器及存储在存储器上并可在处理器上运行的计算机程序,所述处理器执行所述程序时实现如上述的面向CNN网络的移动边缘计算动态卸载方法。

[0142] 本发明还提供了一种计算机可读存储介质,其上存储有计算机程序,该程序被处理器执行时实现如上述的面向CNN网络的移动边缘计算动态卸载方法。

[0143] 采用上述的技术方案,本发明与现有技术相比,其具有的有益效果为:

[0144] (1) 本发明提出了一个资源约束下的海洋智能移动设备延迟改进和能耗改进的加

权和模型,通过动态调整系统权重来优化卸载决策。这种方法不仅考虑了时延与能耗的权衡,还特别关注了设备的剩余功率,旨在延长设备的使用时间,从而提升了MMEC系统的整体性能和可靠性。

[0145] (2) 将MINLP(混合整数非线性规划)问题建模为MAMDP。考虑到目标问题的复杂性,本发明提出了一种创新的部分卸载策略,通过在CNN网络中设置单一分割点来减少数据传输需求,特别适用于偏远环境中数据传输受限的情况。结合网络节点保留算法(NPPR),有效简化了决策过程,提高了卸载策略的实施效率。

[0146] (3) 本发明针对海洋物联网环境中无人机与海面浮标的协同作业,提出了一种基于多智能体深度强化学习(MADRL)的联合优化策略。通过将每个海上移动设备视为独立智能体,对CNN进行垂直划分,并优化边缘服务器(MESs)的资源分配。此外,发明中还设计了一种结合状态归一化和自适应衰减学习率的SA-MADDPG算法,以提升算法对环境变化的适应性,并通过仿真实验验证了其在降低时延能耗与提升续航能力的有效性。

附图说明

[0147] 为了更清楚地说明本发明实施例或现有技术中的技术方案,下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图仅仅是本发明的一些实施例,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。

[0148] 图1是本发明实施例提供的一种面向CNN网络的移动边缘计算动态卸载方法的执行流程图。

[0149] 图2是本发明实施例提供的SA-MADDPG算法框架图。

[0150] 图3是本发明实施例提供的一种电子设备的示意图。

[0151] 图4是本发明实施例提供的一种计算机可读存储介质的示意图。

具体实施方式

[0152] 下面结合附图和实施例,对本发明作进一步的详细描述。特别指出的是,以下实施例仅用于说明本发明,但不对本发明的范围进行限定。同样的,以下实施例仅为本发明的部分实施例而非全部实施例,本领域普通技术人员在没有作出创造性劳动前提下所获得的所有其它实施例,都属于本发明保护的范围。

[0153] 本发明提出了一种改进的部分卸载策略,(1)通过设置单一分割点减少CNN网络的数据传输,并结合网络节点保留算法(NPPR)智能选择任务划分点,以简化决策过程。(2)在MEC的CNN卸载研究中,通常关注能耗与时延的权衡或检测精度。但考虑到环境的动态性,基础设施的缺乏,设备计算资源异构和移动设备间的资源竞争和设备的有限续航能力,本发明提出一种多智能体强化学习算法(MADRL)并将设备的续航能力纳入优化目标。即,本发明在资源受限的条件下,不仅追求多设备之间的时延与能耗的最优权衡,还考虑设备的剩余电量,通过动态调整系统权重,优化卸载决策,以延长设备的使用时间。这一策略旨在提升系统性能和可靠性,为偏远MEC的应用提供了一种新的优化方法。

[0154] 具体而言,在物联网环境中,本发明针对由多个移动设备MMDs和多个边缘服务器MESs,感知设备构成的偏远地区感知与计算场景。提出了一种基于MADRL的联合优化策略,

以解决基于CNN的任务卸载和资源分配问题。该策略将每个移动设备MMD视为独立智能体,对CNN进行垂直划分,并优化MESs的资源分配。为了增强设备的环境自适应能力,引入智能体剩余电量作为优化目标的权重因子,构建离散变量和连续变量的非确定多项式-难(NP-hard)混合整数非线性规划(MINLP)问题,并利用NPPR算法简化问题的解空间。进一步地,将该问题转化为多智能体马尔可夫决策过程(MAMDP),并设计一种结合状态归一化和自适应衰减学习率(SA-MADDPG)算法,以提升算法对环境变化的适应性。

[0155] 请参见图1和图2,本发明的一种面向CNN网络的移动边缘计算动态卸载方法,包括如下步骤:

[0156] 步骤1、数据准备:根据目标检测需求,在通感算一体化系统中获取图像任务数据、设备状态数据和网络状态数据,构成数据集;

[0157] 在本实施例中,所述步骤1具体包括:

[0158] 步骤11、根据用户提交的任务需求,所述通感算一体化系统由多个移动设备和感知设备构成;通感算一体化系统中的感知设备执行数据感知操作,采集并存储图像任务数据;通感算一体化系统同时记录移动设备的设备状态数据和网络状态数据;所述移动设备具有感知、通信、存储和计算的功能,但不要求移动设备必须具有上述感知、通信、存储和计算的部分或全部功能,所述通感算一体化系统由移动设备和感知设备通过有线及无线或仅无线的方式网络链接而成,通感算一体化系统是指同时具备通信、感知和计算能力的网络。

[0159] 步骤12、基于时隙对获取到的图像任务数据、设备状态数据和网络状态数据进行划分,形成设定时间段内的时序数据集;所述时隙是指具有设定时间长度的时间段,在该时间段内获取的数据均标记为该时隙的数据,所述时序数据是指具有时隙属性且按照时隙顺序编号的数据;

[0160] 步骤13、将所述时序数据集划分为训练集、验证集和检测集。

[0161] 步骤2、模型建立:基于通感算一体化系统和数据集,构建通感算一体化系统模型,面向计算任务,将通感算一体化系统模型转化为计算任务切分和资源分配问题;

[0162] 在本实施例中,所述步骤2具体包括:

[0163] 步骤21、通感算一体化系统中具有感知、计算、通信和存储功能的节点通过无线和有线通信的方式或者仅无线的方式相互连接,组成通感算一体化系统模型;所述通感算一体化系统模型按照步骤12中所划分的时隙工作;

[0164] 步骤22、在基于时隙划分的通感算一体化系统模型中,用户在某一时隙发起任务请求;具体为:

[0165] 在基于时隙划分的通感算一体化系统模型中,移动设备MMDs的集合 $\mathbf{M} = \{1, \dots, m, \dots, |\mathbf{M}|\}$,其中,设备m表示在多个移动设备MMDs中选择某一个移动设备MMD,实施任务感知,且均装载了基于CNN网络的计算模块,所述CNN网络包含多个CNN模型,不同的CNN模型对应不同的计算任务;边缘服务器MESs(作为固定设备)的集合 $\mathbf{S} = \{1, \dots, s, \dots, |\mathbf{S}|\}$,其中,设备s表示在多个边缘服务器MESs中选择某一个边缘服务器MES,为周围的移动设备MMDs提供计算资源;设备间通过有线及无线或仅无线的方式组成通感算一体的网络,用户终端通过有线或无线的方式接入该通感算一体的网络,并在某一时隙向该通感算一体的网络发起任务请求;所述请求包含要感知的数据类型和所要求的数据处理要求;所述要求包括但不限于感知范围、感知精度和感知时效等。

[0166] 步骤23、通感算一体化系统模型接收到该任务请求后,实施感知和计算过程;所述计算过程由数据传输和数据处理组成,所述感知和计算过程为通感算一体化过程;具体为:

[0167] 移动设备MMDs负责计算卸载决策的实施,首先,移动设备MMDs选择合适的CNN模型处理检测任务。由于MMDs自身的计算能力和电量有限,移动设备MMDs选择其中一个设备 $s \in S$ 建立通信,将部分工作负载卸载到MES上;整个通感算一体化系统模型以时隙的方式运行,将 T 作为通感算一体化系统整个运行时间,把整个运行时间划分为 T 个长度相等的时隙,则时隙持续时间表示为 $\tau = \lfloor (T/T) \rfloor$, $\lfloor \cdot \rfloor$ 表示向下取整,MMDs在时隙 $t \in \{1, 2, \dots, T\}$ 开始时执行一个目标检测任务;具体的步骤如下:在每个时隙 t 开始时,设备 $m \in M$ 根据用户的提交的需求而生成不同的目标检测任务,不同类别任务所需的CNN模型是异构的,设备 $m \in M$ 需要选择合适的设备 $s \in S$ 建立联系并确定任务卸载部分,每个 $s \in S$ 收到多个 $m \in M$ 的请求并为其分配计算资源。

[0168] 需要说明的是:针对以CNN为基础的计算网络,由于其每一层的网络结构存在串联的关系,即每一层结构的执行需要由前一层的执行结果激活。MMDs为每个网络确定一个分割点,通过分割点将CNN网络分为两个互相依赖的子部分,子部分在MMDs与MES上依次执行。

[0169] 在本实施例中,所述步骤23具体包括:

[0170] 步骤231、根据CNN网络对任务进行分区卸载:

[0171] 假定通感算一体化系统一共有 J 种CNN模型,对于第 j 个CNN模型,其中, $1 \leq j \leq J$,用 L_j 表示第 j 个CNN模型的总层数,第 j 个CNN模型每一层 l_j 的属性为 $(H_{l_j}, W_{l_j}, C_{l_j}^{in}, C_{l_j}^{out}, k_{l_j}, s_{l_j})$,其中, $1 \leq l_j \leq L_j$, $(H_{l_j}, W_{l_j}, C_{l_j}^{in})$ 分别表示 l_j 输入的高度、宽度和通道数量, $(C_{l_j}^{out}, k_{l_j}, s_{l_j})$ 分别表示通道的值、内核大小和步幅大小;CNN网络主要由卷积层 l_j^c 和池化层 l_j^p 构成,在网络的推理过程中,前一层的输出作为下一层的输入,导致各层之间存在依赖关系,并且每一层之间不会相互干扰,为后续网络结构分区和卸载提供理论基础。在计算CNN网络的执行延迟与能耗之前,需要计算网络每层的计算量和输出的参数量。将每一层的计算视为Floating Point Operations (FLOPs),用来衡量YOLO网络层数的计算量。

[0172] 由于网络的计算主要集中在 l_j^c 和 l_j^p 中,为了方便表示,将卷积层和池化层统一用 l_j 表示, l_j 层的总计算量记为 γ_{l_j} ,计算公式为:

$$[0173] \quad \gamma_{l_j} = \begin{cases} 2 * H_{l_j} * W_{l_j} * (C_{l_j}^{in} * (k_{l_j})^2 + 1) * C_{l_j}^{out}, & l_j = l_j^c \\ H_{l_j} * W_{l_j} * C_{l_j}^{in}, & l_j = l_j^p \end{cases}$$

[0174] 在CNN网络的推理过程中,前一层的输出作为下一层的输入,对于 l_j 层的输出量,等同于下一层 l_{j+1} 的输入量,所以输出的数据量记作 δ_{l_j} ,计算公式为:

$$[0175] \quad \delta_{l_j} = W_{l_{j+1}} * H_{l_{j+1}} * C_{l_j}^{out} * p$$

[0176] 其中, p 是单位数据的内存占用;

[0177] 对于分区卸载方式,一个CNN网络存在多个可行的分割点;考虑每个MMD上的任一

CNN网络只存在一个最优分割点,假设分割点为 p_i , i 表示第 i 个分区点,则本地执行第一层到第 p_i 层CNN网络,然后将执行 p_i 层后的中间数据卸载在MES上,MES通过执行 $p_i + 1$ 层一直到最后一层,最后把推断结果传输回MMD;当 $p_i = L_j$ 时,所有任务都在本地进行;当 $p_i = 0$ 时,任务直接卸载到MES上;

[0178] 为了更好地优化网络的分区与卸载,需要判断每个网络中分割点的位置与MMD分配给应用的计算资源,为MMD上的计算任务选择最适合的MES。通过改变CNN网络的分区点与卸载对象,提高系统整体对环境的适应能力。

[0179] 步骤232、获取CNN网络的计算延迟和传输延迟:

[0180] CNN推理延迟主要是由计算延迟和传输延迟构成,计算延迟由CNN在MMDs和MESs上执行产生,与模型规模和设备计算资源有关。传输延迟受到网络带宽和传输数据量影响。

[0181] (1) MMD上的执行时间:令 F_m^{local} 表示设备 m 的计算资源,其中在时隙 t 内分配给设备 m 的本地执行应用的计算资源为 f_m^{local} , $f_m^{local} \leq F_m^{local}$;本地执行时间 $d_m^{local}(t)$ 为:

$$[0182] \quad d_m^{local}(t) = \sum_{l_j=0}^{p_i^j} \frac{\gamma_{l_j, m}(t)}{f_m^{local}}$$

[0183] 其中, $\sum_{l_j=0}^{p_i^j} \gamma_{l_j, m}(t)$ 表示在时隙 t 中设备 m 上,第一层和划分层 p_i^j 之间所有层的计算量之和, p_i^j 表示第 j 个CNN模型第 i 个分区点层数; $\gamma_{l_j, m}(t)$ 表示在时隙 t 中设备 m 上第 l_j 层的计算量;

[0184] (2) 中间输出数据的传输时间:

[0185] 设备 $s \in S$ 到设备 $m \in M$ 之间通信链路的信道增益 $g_{m, s}$ 建模为:

$$[0186] \quad g_{m, s} = \frac{g_0}{d_{m, s}^2}$$

[0187] 其中, $d_{m, s}$ 表示对应设备间的欧氏距离, g_0 表示参考距离为1m时的信道增益;则对应的传输速率 $r_{m, s}^{up}$ 定义为:

$$[0188] \quad r_{m, s}^{up} = B_{ul} \log_2 \left(1 + \frac{p_m^{up} g_{m, s}}{\sigma^2} \right)$$

[0189] 其中, B_{ul} 为边缘计算网络的传输带宽, p_m^{up} 为无人机的传输功率, σ 为波导信道噪声;令 $\delta_{p_i^j, m}(t)$ 表示在 t 时隙期间设备 m 在分区层 p_i^j 传输的数据大小,得到设备 m 卸载到设备 s 的传输延迟 $d_{m, s}^{up}(t)$ 为:

$$[0190] \quad d_{m, s}^{up}(t) = \frac{\delta_{p_i^j, m}(t)}{r_{m, s}^{up}}$$

[0191] 由于结果数据的大小远远小于输入数据的大小,所以忽略了将检测后的结果传输回本地设备的延时。

[0192] 由于MES需要对多个MMD进行计算卸载,且MES中的CNN模型比MMD的CNN模型更复杂,即需要考虑目标检测任务在MES的计算延迟以及多个任务之间的排队延迟;令 $f_{m,s}^{edge}$ 表示在时隙 t 内设备 $s \in S$ 分配给设备 $m \in M'$ 的计算资源,其中, $\sum_{m \in M'} f_{m,s}^{edge} \leq F_s^{edge}$, M' 为设备 s 同一时间提供计算服务的MMD设备集合, F_s^{edge} 为设备 s 的总计算资源;因此,计算出在 t 时隙,设备 m 在设备 s 上的执行延迟 $d_{m,s}^{edge}(t)$ 为:

$$[0193] \quad d_{m,s}^{edge}(t) = \sum_{l_j=p_i^j+1}^{L_j} \frac{\gamma_{l_j,s}(t)}{f_{m,s}^{edge}}$$

[0194] 其中, $\sum_{l_j=p_i^j+1}^{L_j} \gamma_{l_j,s}(t)$ 表示传输到设备 s 上的CNN网络分区在第 p_i^j 层后的部分的局部计算量; $\gamma_{l_j,s}(t)$ 表示在时隙 t 中设备 s 上第 l_j 层的计算量;

[0195] 因此,在划分一个目标检测任务后,设备 m 的总执行时间 $d_m(t)$ 等于MMD上的本地执行时间、中间数据传输时间以及MES上的执行时间之和:

$$[0196] \quad d_m(t) = d_m^{local}(t) + d_{m,s}^{up}(t) + d_{m,s}^{edge}(t)$$

[0197] 假定每个 m 的每个任务必须在单个时隙时间内完成,即 $d_m(t) \leq \tau$

[0198] 步骤233、计算能量消耗:

[0199] (1) MMD上的执行能耗:假设 p_m^{local} 表示设备 m 的计算功率,则设备 m 本地执行能耗 $E_m^{local}(t)$ 为:

$$[0200] \quad E_m^{local}(t) = p_m^{local} d_m^{local}(t)$$

[0201] (2) 设备 m 中间输出数据的传输能耗 $E_m^{up}(t)$ 为:

$$[0202] \quad E_m^{up}(t) = p_m^{up} d_m^{up}(t)$$

[0203] 其中, p_m^{up} 表示 m 的传输功率;

[0204] (3) 设备 m 执行任务所损耗的能耗为:

$$[0205] \quad E_m^v(t) = p_m^v d_m(t)$$

[0206] 其中, p_m^v 表示设备 m 执行任务时的平均功率;

[0207] (4) 当设备 m 执行部分CNN网络任务的总能量消耗 $E_m(t)$ 是本地执行能耗、中间输出数据的传输能耗以及执行任务所损耗的能耗之和:

$$[0208] \quad E_m(t) = E_m^{local}(t) + E_m^{up}(t) + E_m^v(t)$$

[0209] 步骤234、计算服务质量:

[0210] (1) 由设备 m 和设备 s 组成的计算过程的服务质量 $u_{m,s}^{QoS}$ 受到任务延迟和能量消耗的双重影响;用 $u_{m,s}^e$ 和 $u_{m,s}^d$ 分别表示MMDs的能耗和时延的改善水平; $u_{m,s}^e$ 描述了通过计算卸载

MMDs所节省的能源占当地能源消耗的比例, $u_{m,s}^d$ 表示通过MESs计算卸载,与本地延迟相比,时延的降低比例;因此,MMD的能耗和改善水平分别表示为:

$$[0211] \quad u_{m,s}^e = \frac{E_m'(t) - E_m(t)}{E_m'(t)}$$

[0212] 和

$$[0213] \quad u_{m,s}^d = \frac{d_m'(t) - d_m(t)}{d_m'(t)}$$

[0214] 其中, $d_m'(t)$ 和 $E_m'(t)$ 分别表示在时隙 t 期间设备 m 完全在本地执行任务时的延迟和能耗;

[0215] (2) 对于具有不同剩余电池电量的无人机,卸载策略在节能和延迟降低方面具有不同的偏好。因此,引入权重因子 $\omega_{m,s}$ 来衡量MMD在节能和延迟降低之间的权衡,考虑 MMD 的剩余电池电量,并将剩余电量比 E_m^{re} 进一步纳入权重因子,其中:

$$[0216] \quad E_m^{re} = \frac{E_m^{remain}}{E_m^{full}}$$

[0217] 其中, E_m^{remain} 和 E_m^{full} 分别表示设备的当前最大电池容量和当前剩余电量;

[0218] (3) 能耗改进和延迟改进的加权总和表示为:

$$[0219] \quad f_{m,s} = \omega_{m,s} E_m^{re} u_{m,s}^d + (1 - \omega_{m,s} E_m^{re}) u_{m,s}^e$$

[0220] 通过调整权重因子,MMDs可以节省更多的能量或减少延迟。低延迟要求更快的计算时间和传输速度,这将加剧MMDs的能耗。相反,较低的剩余功率限制了延迟改进的水平,即使MMDs对延迟改进有强烈的偏好。

[0221] (4) 利用指数函数表征能耗改善和延迟改善的权衡模型与MMDs服务质量 $U_{m,s}^{QoS}$ 之间的映射关系,定义为:

$$[0222] \quad U_{m,s}^{QoS} = a^{f_{m,s} - 1}$$

[0223] 其中, a 表示变量参数, $a > 1$ 为正整数,此时 $f_{m,s}$ 表示 a 的指数;

[0224] (5) 根据 $f_{m,s} = \omega_{m,s} E_m^{re} u_{m,s}^d + (1 - \omega_{m,s} E_m^{re}) u_{m,s}^e$ 推导出 $-\infty < f_{m,s} < 1$, 因此,推导出 $U_{m,s}^{QoS}$ 的取值上界和下界分别为 $a - 1$ 和 -1 ;

[0225] 步骤235、定义目标问题:

[0226] 调度策略主要包括根据MMD的剩余电池电量实时动态调整延迟和能耗的权重比,并最小化系统延迟和能耗;每个 MMD 都有一个相应的 $U_{m,s}^{QoS}$ 指标,每个MMD通过决策 p_i^j 、 $f_{m,s}^{edge}$ 和 $\phi_{m,s}$ 来实施计算任务执行,并优化系统中所有MMD的 $U_{m,s}^{QoS}$,其中, $\phi_{m,s}$ 表示设备 m 选择设备 s 的决策,如下所示:

$$[0227] \quad \max_{\{p_i^j, f_{m,s}^{edge}, o_{m,s}\}} \frac{1}{T} \sum_{t=1}^T \sum_{m \in M} \sum_{s \in S} u_{m,s}^{QoS}(t)$$

$$[0228] \quad \text{s. t.} \quad \sum_{m \in M'} f_{m,s}^{edge} \leq F_s^{edge}$$

$$[0229] \quad 0 \leq p_i^j \leq L_j$$

$$[0230] \quad 0 \leq o_{m,s} < |S|$$

$$[0231] \quad 0 \leq E_m^{remain} \leq E_m^{full}$$

[0232] 结合方程推断出目标问题是一个混合整数非线性规划(MINLP)问题,也是一个非确定多项式-难(NP-Hard)问题;

[0233] 约束 $\sum_{m \in M'} f_{m,s}^{edge} \leq F_s^{edge}$ 表示设备s分配给设备m的计算资源不得超过最大可用本地计算资源; $0 \leq p_i^j \leq L_j$ 表示目标检测模型的分区点选择必须在目标检测模型的层数范围内; $0 \leq o_{m,s} < |S|$ 表示MMD对MESs的选择必须从集合S中选择, $0 \leq E_m^{remain} \leq E_m^{full}$ 表示MMD的剩余电池电量不超过其最大容量。

[0234] 步骤3、模型转化:基于通感算一体化系统模型和计算任务切分和资源分配问题,构建马尔可夫决策模型;

[0235] 在本实施例中,所述步骤3具体包括:

[0236] 步骤31、每个设备m被视为一个智能体,将计算任务切分和资源分配问题进一步表示为一个多智能体马尔可夫决策过程(MAMDP),并构建马尔可夫决策模型;

[0237] 步骤32、根据环境状态自适应地确定每个设备的卸载决策,以最大化用户服务质量;将马尔可夫决策模型表示为 (S', A, P, R) ,其中, S' 是状态空间, A 是动作空间, P 是状态转移概率矩阵, R 是奖励;马尔可夫决策模型的状态、动作和奖励如下:

[0238] 状态:状态空间由MMD和MES的状态组成,这些状态在不同时期演变;时隙t时刻的状态空间 S' 定义为 s_m :

$$[0239] \quad s_m = \{l_m^{ta}, f_m^{local}, E_m^{remain}, f_{m,s}^{edge}, r_{m,s}^{up}\}$$

[0240] 其中, l_m^{ta} 为时隙t时刻设备m上携带的CNN模型类别, f_m^{local} 表示在时隙t内分配给设备m的本地执行应用的计算资源, E_m^{remain} 表示t时隙时设备m的剩余电量, $f_{m,s}^{edge}$ 表示在t时隙内设备 $s \in S$ 分配给设备 $m \in M'$ 的计算资源,通过广播的形式发送给每个MMD;

$r_{m,s}^{up} = \{r_{m,1}^{up}, r_{m,2}^{up}, \dots, r_{m,|S|}^{up}\}$ 表示设备m与设备S之间的上行容量;

[0241] 动作:设备通过其动作影响环境;所有设备m的动作集是一个混合整数和非整数卸载决策向量,设备m在时隙t的动作表示为:

$$[0242] \quad a_m = \{o_{m,s}, p_i^j, f_{m,s}^{edge}\}$$

[0243] 其中, $\phi_{m,s}$ 表示MMD卸载任务的卸载决策, p_i^j 表示MMD上携带的CNN 网络的分区;

[0244] 奖励:在马尔可夫决策过程(MDP))中,奖励是指在时隙 t 的状态 s_m 下采取动作所获得的系统收益;由于强化学习模型通过最大化累积奖励进行学习,因此适当的奖励函数对于优化强化学习性能至关重要。当设备 s 完成向设备 m 传输的任务时,设备 m 生成服务质量 $U_{m,s}^{QoS}(t)$ 反馈,MESs协作以实现所有设备的服务质量 $U_{m,s}^{QoS}(t)$ 最大化为目标;因此,奖励函数表示为:

$$[0245] \quad R = \frac{1}{T} \sum_{t=1}^T \sum_{m \in M} \sum_{s \in S} U_{m,s}^{QoS}(t)。$$

[0246] 步骤4、模型训练:基于马尔可夫决策模型和多智能体深度强化学习算法(MADRL)得到联合优化策略,通过数据集进行训练,获得满足终止条件的神经网络参数模型;

[0247] 在本实施例中,所述步骤4具体包括:

[0248] 步骤41、基于网络节点保留算法(NPPR)进行网络切分节点确定:

[0249] (1) 由于CNN网络的复杂性,可能存在多个潜在分区点,导致多智能体马尔可夫决策过程(MAMDP)中的解空间复杂。在确定近似最优卸载和资源分配策略之前,引入一种网络节点保留算法(NPPR)。通过保留合适数量的网络节点,降低后续算法的复杂性。

[0250] 由于某些网络层的输出数据量较大,在低带宽条件下会导致较高的通信成本,因此它们不适合作为潜在分区点。首先,选择一个CNN模型 j 作为预处理的目标,计算不同带宽 B_k 下所有分区点对应的执行时间 $T_{p_i^j}$, $B_k \leq B_{ul}$; 定义 ζ 为保留分区层的集合; 定义 ζ_j^k 为带宽 B_k 对应的分区层集合; 定义 ζ_j 为当前CNN模型 j 对应的候选点集;

[0251] 计算相同带宽 B_k 下所有分区点的平均执行时间 T_{avg}^j , 如下式所示:

$$[0252] \quad T_{avg}^j = \sum_{p_i=1}^{L_j} T_{p_i^j} / L_j$$

[0253] (2) 令 ψ 为一个在 $[0, 1]$ 范围内的权重因子,将每个节点与平均执行时间和权重因子 ψ 的乘积进行比较;如果 $T_{p_i^j}$ 小于 ψT_{avg}^j , 则保留该节点至 ζ_j^k ; 否则,消除该节点;最后获得带宽 B_k 对应的 ζ_j^k ;

[0254] (3) 通过公式:

$$[0255] \quad \zeta_j = \zeta_j \cap \zeta_j^k$$

[0256] 更新 ζ_j , 当取不同的 B_k 值时,重复步骤41中的(1)~(3),直至遍历所有的带宽 B_k , 获得最终的 ζ_j ;

[0257] (4) 将所有类型CNN模型的候选点集 ζ_j 整合到 ζ 中;

[0258] 步骤42、基于多智能体深度强化学习算法(MADRL)进行联合优化策略:

[0259] (1) 在多智能体协作环境中集成了MADDPG框架,由于环境中智能体之间的合作和竞争,孤立的强化学习算法对单个智能体不可行。因此,部署一个协作多智能体框架,以确保所有智能体之间的合理调度策略。每个智能体上携带的 DDPG算法集成了策略梯度和深

度Q网络(DQN)的优势。

[0260] 每个智能体由一个演员(Actor)网络 μ 和一个评论(Critic)家网络 Q 组成,两者都由深度神经网络参数化;演员网络以状态观察为输入,并根据策略 π 输出动作;同时,评论家网络使用状态-动作函数 $Q(s, a)$ 根据当前状态评估演员网络选择的动作;

[0261] (2)在MADDPG框架中,与单智能体使用的算法类似,MADDPG 框架将集中训练与分散执行相结合。每个目标网络以多个智能体的全局状态为输入,以评估这些状态下动作的质量;目标网络通过生成暂时延迟的目标策略和价值估计来促进稳定学习;在MADDPG框架中,演员网络根据其本地智能体观察状态 s_m 确定本地动作 a_m ,每个智能体的策略参数定义为 $\theta = [\theta_1, \theta_2, \dots, \theta_{|M|}]$,其中, θ_m 表示第 m 个智能体的策略参数,每个智能体采用由 θ_m^μ 参数化的连续策略 μ_m^θ , θ_m^μ 为智能体 m 的演员网络参数;在确定性策略框架下,每个智能体采用连续策略 $a_m = \mu_m^\theta(s_m | \theta_m^\mu) + N$,其中 N 是用于增强系统探索能力的随机噪声;在MADDPG框架内,当前智能体采取的实际动作在经过一定通信后可以被系统中的其他智能体感知。

[0262] (3)评论家网络将智能体的状态 s_m 和动作 a_m 作为输入,表示为 $Q_m(s_m, a_m | \theta_m^Q)$,其中, θ_m^Q 为评论家网络的网络参数,评论家网络用于对集体性能 $Q_m(s_m, a_m)$ 进行全局评估,其输入包括所有智能体的动作和状态;与DQN类似,MADDPG 通过目标网络和经验回放缓冲区增强系统稳定性。智能体的目标演员网络定义为 μ_m' ,对应的网络参数定义为 $\theta_m^{\mu'}$,目标网络表示为 Q' ,对应的网络参数为 $\theta_m^{Q'}$;这些参数的更新公式定义为:

$$[0263] \quad \begin{cases} \theta_m^{\mu'} \leftarrow \eta \theta_m^{\mu'} + (1-\eta) \theta_m^{\mu} \\ \theta_m^{Q'} \leftarrow \eta \theta_m^{Q'} + (1+\eta) \theta_m^Q \end{cases}$$

[0264] 其中,参数 η 表示一个在0到1范围内的系数;

[0265] (4)MADDPG算法包括两个阶段:集中离线训练和分散执行;在集中离线训练阶段,每个智能体不仅利用自己的观察,还利用其他智能体的观察和动作进行策略评估。每个智能体可以根据其本地观察选择动作,并使用评论家网络评估所选动作。通过采用状态-动作价值函数 Q_m 简化训练,该函数可以根据当前观察-动作对预测长期预期回报。在分散执行阶段,每个智能体只能访问自己的状态,并独立决定其动作,而不知道其他智能体的情况。

[0266] 在集中离线训练过程中,系统收集智能体的状态信息 $[s_m, a_m, r_m, s_m']$,其中 s_m' 表示状态为 s_m 时执行动作 a_m 后进入的下一个状态,此状态信息存储在经验回放缓冲区中; $r_m = \sum_{s \in s} s u_{m,s}^{QoS}(t)$ 是当前动作获得的奖励值;在将数据收集到经验回放缓冲区 $\mathcal{R}$ 后,随机采样用于策略评估过程;MADDPG算法遵循离线策略方法,使用采样数据更新 Q 和 μ 的参数;目标函数更新表示为:

$$[0267] \quad y_m = r_m + \gamma Q'(s_m', a_m' | \theta_m^{Q'}) |_{a_m' = \mu_m'(s_m')}$$

[0268] 其中, γ 表示折扣因子, a_m' 是通过公式: $a_m' = \mu_m'(s_m')$ 得到,通过最小化损失函数

来更新评论家网络(the critic network):

$$[0269] \quad L(\theta_m^Q) = E[Q(s_m, a_m | \theta_m^Q) - y_m]^2$$

[0270] 其中, $E[\cdot]$ 表示求期望;

[0271] 在更新评论家网络后, 演员网络(the actor network)通过以下公式进行参数 θ_m^μ 的更新:

$$[0272] \quad \nabla_{\theta_m^Q} L(\theta_m^Q) = E[2(y_m - Q(s_m, a_m | \theta_m^Q)) \nabla_{\theta_m^Q} (Q(s_m, a_m))]$$

[0273] 其中, $\nabla_{\theta_m^Q}$ 表示参数 θ_m^Q 的梯度;

[0274] 然后, 评论家网络根据神经网络的梯度规则更新其参数, 得到:

$$[0275] \quad \theta_m^Q \leftarrow \theta_m^Q - \varepsilon \nabla_{\theta_m^Q} L(\theta_m^Q)$$

[0276] 其中, ε 为评论家网络的学习率, 然后, 利用策略梯度法对演员网络进行更新, 得到:

$$[0277] \quad \nabla_{\theta_m^\mu} \mu = \nabla_{a_m} Q(s_m, a_m | \theta_m^Q) \Big|_{s = s_m, a_m = \mu_m^\mu(s_m | \theta_m^\mu)} \nabla_{\theta_m^\mu} \mu(s_m | \theta_m^\mu)$$

[0278] 演员网络参数更新为:

$$[0279] \quad \theta_m^\mu \leftarrow \theta_m^\mu + \beta \nabla_{\theta_m^\mu} \mu$$

[0280] 其中, β 为评论家网络的学习率; μ 表示演员网络; $\nabla_{\theta_m^\mu} \mu$ 表示对演员网络 μ 求关于参数 θ_m^μ 的梯度;

[0281] 步骤43、多智能体深度强化学习算法的标准化和自适应学习率:

[0282] (1) 在多智能体深度强化学习算法的初始化过程中, 通过在临时内存中存储训练期间的最大值和最小值并计算缩放因子来对环境状态进行标准化, 解决了输入变量的量级差异问题, 并通过标准化计算提高了训练效率。每个环境变量的最大值和最小值之差作为缩放因子; 通过从当前状态中减去最小值并除以获得的缩放因子, 得到标准化的状态信息;

[0283] (2) 在强化学习的训练过程中, 由于环境的不确定性、奖励的稀疏性和模型本身的复杂性, 固定学习率往往不足以满足整个训练过程的需求。因此, 采用衰减学习率策略根据不同训练阶段的损失率调整学习率的大小:

$$[0284] \quad \begin{cases} \varepsilon \leftarrow \varepsilon * \omega \\ \beta \leftarrow \beta * \omega \end{cases}$$

[0285] 其中, ω 是学习率衰减系数。当监测指标不再改善时, 系统的学习率可以降低。

[0286] 步骤5、模型部署: 将训练好的神经网络参数模型部署到通感算一体化系统中;

[0287] 在本实施例中, 所述步骤5具体包括:

[0288] 步骤51、根据环境动态信息, 以设定的时间间隔, 将训练好的神经网络参数同步至CNN网络中每个节点; 所述时间间隔取决于新的神经网络参数训练过程是否收敛到新的状态;

[0289] 步骤52、CNN网络中各节点基于获得的神经网络参数更新卸载策略和资源分配策略;

[0290] 步骤53、CNN网络中各节点向通感算一体化系统反馈更新后的策略状态。

[0291] 步骤6、决策实施：根据实时的图像任务数据、设备状态数据和网络状态数据，产生计算任务切分决策和计算资源分配决策，并将决策结果信息传输至通感算一体化系统的各节点，最终实现计算任务的卸载。

[0292] 在本实施例中，所述步骤6具体包括：

[0293] 步骤61、通感算一体化系统获得实时的网络状态数据和设备状态数据，感知设备根据用户需求获得实时的图像任务数据；

[0294] 步骤62、基于输入的网络状态数据、设备状态数据和图像任务数据，根据神经网络所确定的多智能体马尔可夫决策模型，产生计算任务的切分和计算资源的分配决策；

[0295] 步骤63、将决策结果信息同步至通感算一体化系统中各节点；

[0296] 步骤64、各节点实施执行具体的计算任务。

[0297] 如图3所示，本发明实施例还提供一种电子设备，包括存储器、处理器及存储在存储器上并可在处理器上运行的计算机程序，所述处理器执行所述程序时实现上述的面向CNN网络的移动边缘计算动态卸载方法。

[0298] 如图4所示，本发明实施例还提供一种计算机可读存储介质，其上存储有计算机程序，该程序被处理器执行时实现上述的面向CNN网络的移动边缘计算动态卸载方法。

[0299] 另外，在本发明各个实施方式中的各功能单元可以集成在一个处理单元中，也可以是各个单元单独物理存在，也可以两个或两个以上单元集成在一个单元中。上述集成的单元既可以采用硬件的形式实现，也可以采用软件功能单元的形式实现。

[0300] 集成的单元如果以软件功能单元的形式实现并作为独立的产品销售或使用，可以存储在一个计算机可读存储介质中。基于这样的理解，本发明的技术方案本质上或者说对现有技术做出贡献的部分或者该技术方案的全部或部分可以以软件产品的形式体现出来，该计算机软件产品存储在一个存储介质中，包括若干指令用以使得一台计算机设备（可以是个人计算机，服务器，或者网络设备等）或处理器（processor）执行本发明各个实施方式方法的全部或部分步骤。而前述的存储介质包括：U盘、移动硬盘、只读存储器（ROM，Read-Only Memory）、随机存取存储器（RAM，Random Access Memory）、磁碟或者光盘等各种可以存储程序代码的介质。

[0301] 以上所述仅为本发明的部分实施例，并非因此限制本发明的保护范围，凡是利用本发明说明书及附图内容所作的等效装置或等效流程变换，或直接或间接运用在其他相关的技术领域，均同理包括在本发明的专利保护范围内。

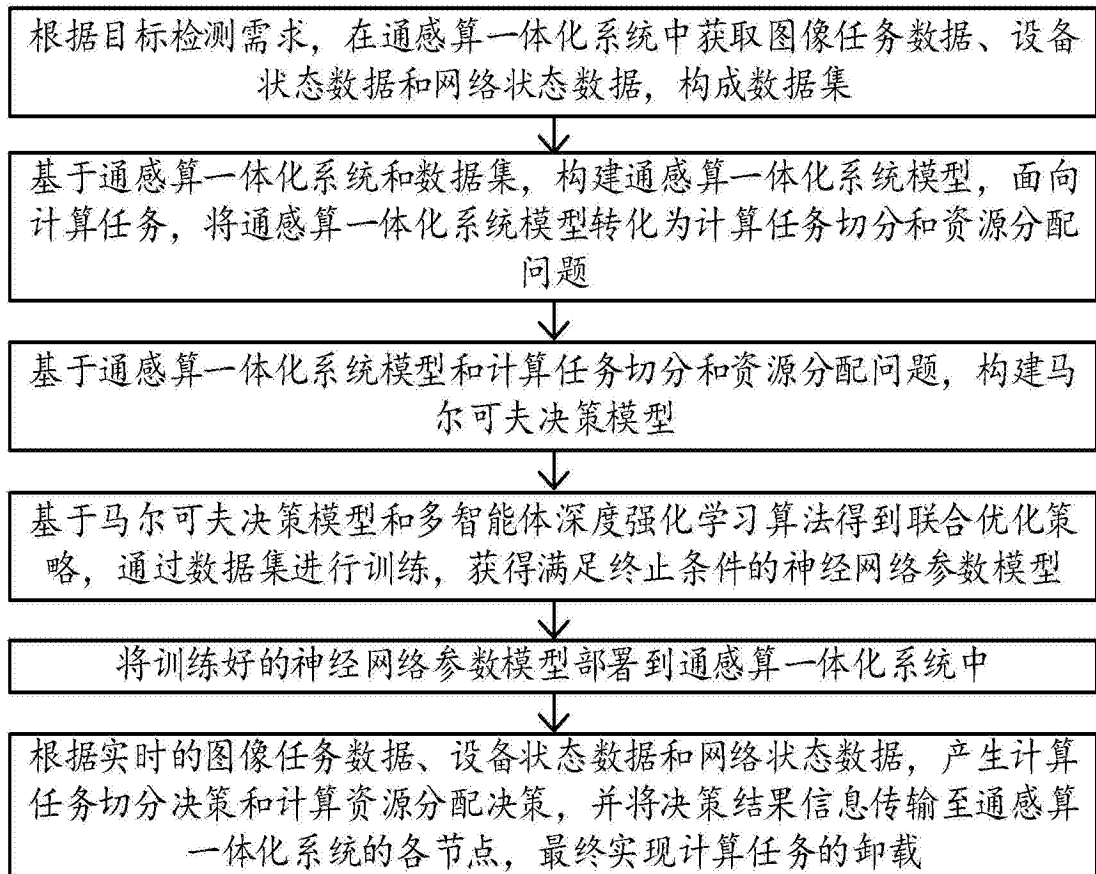


图1




图2




图3




图4